PLDAC - Etude de différentes techniques pour la classification de signaux d'EEG et MEG

Buton Nicolas

May 16, 2019

Table des matières

Part I
Introduction

Notre etude ce place dans le cadre de l'annalyse de série temporelle multivarier, qui comporte une dimension temporel et un spatiale.

Les interfaces cerveaux machines ont besoin de réagir vite et donc on doit analyser le signal sur un laps de temps court.

Historiquement cela ce faisait avec des méthodes linéaire, cela avait des performances assez faible et il fallait donc répéter l'expérience plusieurs fois comme c'est fait dans les méthodes P300(à détailler).
Barachant à ensuite proposer les méthodes riemannien qui sont plus robuste et qui ont permit d'attaquer des taches plus compliqué comme le transfert entre sujet.

Les signaux étudié seront des signaux d'Électroencéphalographie(EEG) et de Magnétoencéphalographie(MEG). Le premier consiste a enregistrer les signaux électrique a la surface du crane grâce a des électrodes, le second enregistre l'activité magnétique induite par l'activité des neurones grâce a un ensemble de magnétomètre.

L'une des difficultés pour traiter ces signaux est le fait que les électrodes ne sont jamais situées exactement au même endroit sur le crane entre chaque essai, et entre chaque personne. De plus il peut y avoir beaucoup de bruit généré par le matériel ou les mouvement de l'utilisateur par exemple.

Pour être résistant au bruit on a donc besoin de manipuler des matrices de covariance et pour cela un moyen est d'utiliser la géométrie de Riemann qui peut définir une distance entre matrice définit positive, les matrices de covariance font partie de ce groupe. La deuxième méthode consiste a aplatir la matrice.

C'est pour cela que dans les méthodes de l'état de l'art la géométrie riemannienne est utilisé. Ces méthode permette aussi un meilleur sucées pour le transfert d'un sujet à un autre.

Par la suite nous allons comparer ces méthodes avec de la géométrie riemannienne avec d'autres méthodes plus classique, ainsi qu'une méthode de deep learning.

Dans ce rapport nous étudierons nos méthodes sur 3 datasets différents : Eye close/eye open, brain invader et DecMeg2014.

Part II
État de l'art - la géometrie de riemann

1 Distance

Pour deux matrice $\mathbf{\Sigma}_1$ et $\mathbf{\Sigma}_2$ leurs distances est d'après la géométrie de Riemann est la suivante :

$$\delta_R(\mathbf{\Sigma}_1, \mathbf{\Sigma}_2) = \|\log\left(\mathbf{\Sigma}_1^{-1/2}\mathbf{\Sigma}_2\mathbf{\Sigma}_1^{-1/2}\right)\|_F = \left[\sum_{c=1}^{C}\log^2\lambda_c\right]^{1/2}, \tag{1}$$

où $\lambda_c, c = 1 \dots C$ sont les valeurs propres réelles de $\mathbf{\Sigma}_1^{-1/2}\mathbf{\Sigma}_2\mathbf{\Sigma}_1^{-1/2}$ et C le nombre d'électrodes.
F :Norme de Frobenius

2 Point moyen

Pour définir la matrice moyenne nous ne possédons pas d'expression explicite.

$$\mathfrak{G}\left(\mathbf{\Sigma}_1, \dots, \mathbf{\Sigma}_I\right) = \arg\min_{\mathbf{\Sigma}} \sum_{i=1}^{I} \delta_R^2\left(\mathbf{\Sigma}, \mathbf{\Sigma}_i\right). \tag{2}$$

Pour la calculer on peut utiliser une descente de gradient.

3 Espace tangent

On peut projeter un point de l'espace de Riemann définit par une matrice NxN sur un espace tangent avec N(N+1)/2 dimensions.

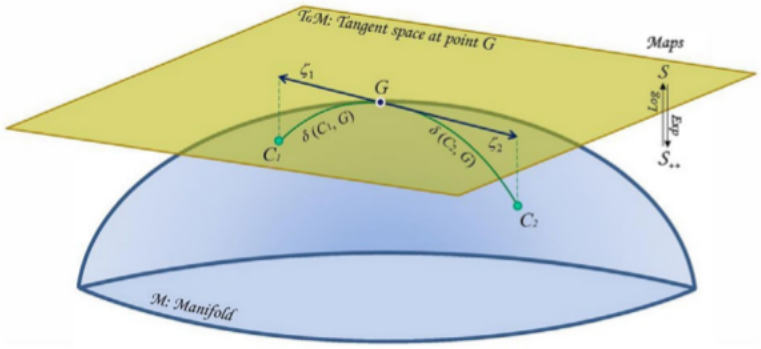

Figure 1: Affichage del'espace tangent

Article sur la géométrie de Riemann :
- Brain invader [1]
- Geometrie de riemann [2]

Part III
Les différents modèles

Nous allons représenter a l'aide d'un graphe les différentes méthodes que nous allons tester par la suite.

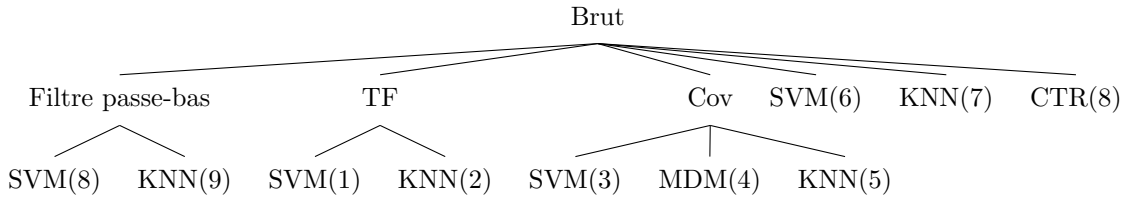

Légende :
Cov : Matrice de covariance
TF : Transformé de fourier
MDM : Minimum Distance to Mean
CTR : Chaine de traitement riemannienne, détaillé plus loin.
Prédiction théorique :
La méthode 6 et 7 ne devrais pas fonctionner car avec une seule données c'est difficile de faire quoi que ce soit.
La méthode 8 et 9 ne devrais pas fonctionner car il n'y aura pas invariance par translation.
De plus nous introduirons une nouvelle méthode plus complexe dans le dernier dataset DecMeg2014.

0.1 Format des données

En entrée deux format sont possible. Le premier est une serie temporel pour chaque éléctrodes ainssi que les labels pour chaque données d'entrée.
Notons :
- C : le nombre de canaux.
- T : le temps écoulé en seconde pendant l'enregistrement des données.
- f : la fréquence d'échantillonnage du signal.

Nous dispossons donc d'une matrice de taille Cx(T*f), ainsi que d'un vecteur de label de taille (T*f).
Mais un deuxieme format d'entrée est possible, en découpant par trial, a chaque trial correspond un label.
Notons :
TT : le temps d'un trial.
NT : le nombre de trial.
Nous disposons donc d'un tenseur de taille (TT*f)xCxNT, et d'un vecteur de label de taille NT.
On peut passer du premier formalisme a l'autre en découpant par trial(en définissant une taille de fenêtre)

mais nous avons plusieurs possibilité pour savoir quels labels associé a ce trial (label majoritaire,premier label,dernier label,etc...).

0.2 Description des modèles

1 et 2 - SVM et KNNavec une transformer de fourrier La première étape de notre modèle est d'effectuer une transformer de fourrier, c'est a dire passé d'un signal temporel à un signal fréquentiel. Pour calculer nous utiliserons l'algorithme FFT(Fast fourier transform).Nous garderons uniquement le modules pour rester avec des valeurs réelles plutôt que complexe.

Ensuite nous utilisons un SVM pour prédire les labels dans un cas et un KNN dans l'autre.

3,4 et 5 - SVM,MDM et KNN avec matrice de covariance Pour cette approche nous devons passer au deuxième format de données(décrit dans la partie précédente), si les données nous sont donné dans le premier format nous devons définir une taille de fenêtre et une méthode d'attribution des labels.
Ensuite on calcul la matrice de covariance :
$\mathbf{\Sigma}_i = \frac{1}{C}\tilde{\mathbf{X}}\overline{\mathbf{X}}^T$ Avec X ma matrice d'entrée.

6 et 7 - SVM et KNN sur les données brut

8 et 9 - SVM et KNN avec un filtre passe bas

8 - Chaine de traitement riemannienne 1 - On garde uniquement 1 secondes sur les 1.5 secondes de signal car le stimulus intervient qu'après 0.5 secondes.
2 - On filtre le signal avec un filtre passe bande de Butterworth d'ordre 5 entre 1Hz et 20Hz.

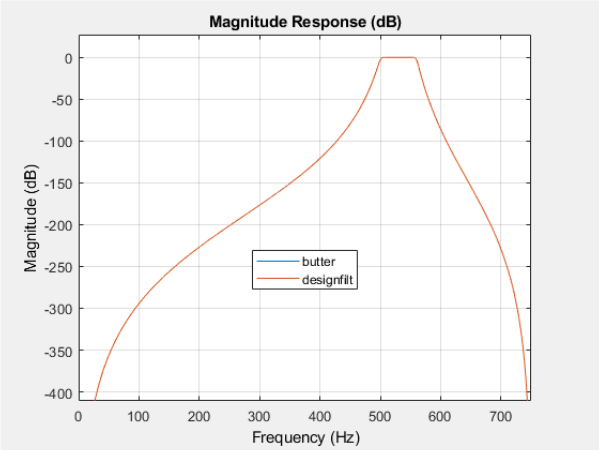

Figure 2: butterworth filter

3 - Par la suite on effectue un filtrage spatial, on extrait 4 channel virtuel par classe.

$$\mathbf{P}^{(k)} = \frac{1}{|\mathcal{I}^{(k)}|} \sum_{i \in \mathcal{I}^{(k)}} \mathbf{X}_i,$$

Figure 3: P moyen

$$\mathbf{w}^* = \arg\max_{\mathbf{w}} \frac{\mathbf{w}^T \mathbf{P}^{(k)} {\mathbf{P}^{(k)}}^T \mathbf{w}}{\mathbf{w}^T \mathbf{X}\mathbf{X}^T \mathbf{w}}.$$

Figure 4: spatial filtering

$$\mathbf{Z}_i = \mathbf{W}^T \mathbf{X}_i$$

Figure 5: Zi

$$\tilde{\mathbf{Z}}_i = \begin{bmatrix} \mathbf{W}^{(0)^T} \mathbf{P}^{(0)} \\ \mathbf{W}^{(1)^T} \mathbf{P}^{(1)} \\ \mathbf{Z}_i \end{bmatrix}.$$

Figure 6: features space

$$\mathbf{\Sigma}_i = \frac{1}{N} \tilde{\mathbf{Z}}_i \tilde{\mathbf{Z}}_i^T$$

Figure 7: covariance

4 - On définit une nouvelle entrée comme étant la concaténation :
- du signal moyen de la classe 1 auquel on multiple par W0 pour les projeter sur les channels virtuelles appris précédemment.
- idem pour la classe 2
- Et ensuite le signal Xi projeter sur les 8 channels.
5 - On calcul la covariance de cette matrice.
6 - On projette cette matrice sur l'espace tangent.
7 - On estime pour les 15 autre sujets avec ce filtre spatial 8 - On fait la même chose pour les 15 autres sujet et on concaténe.
9 - Régression logistique avec une régularisation lasso.
Les figures suivantes représentes la forme des matrices au fur et a mesure du processus. Elles sont a lire de gauche a droite et de haut en bas.

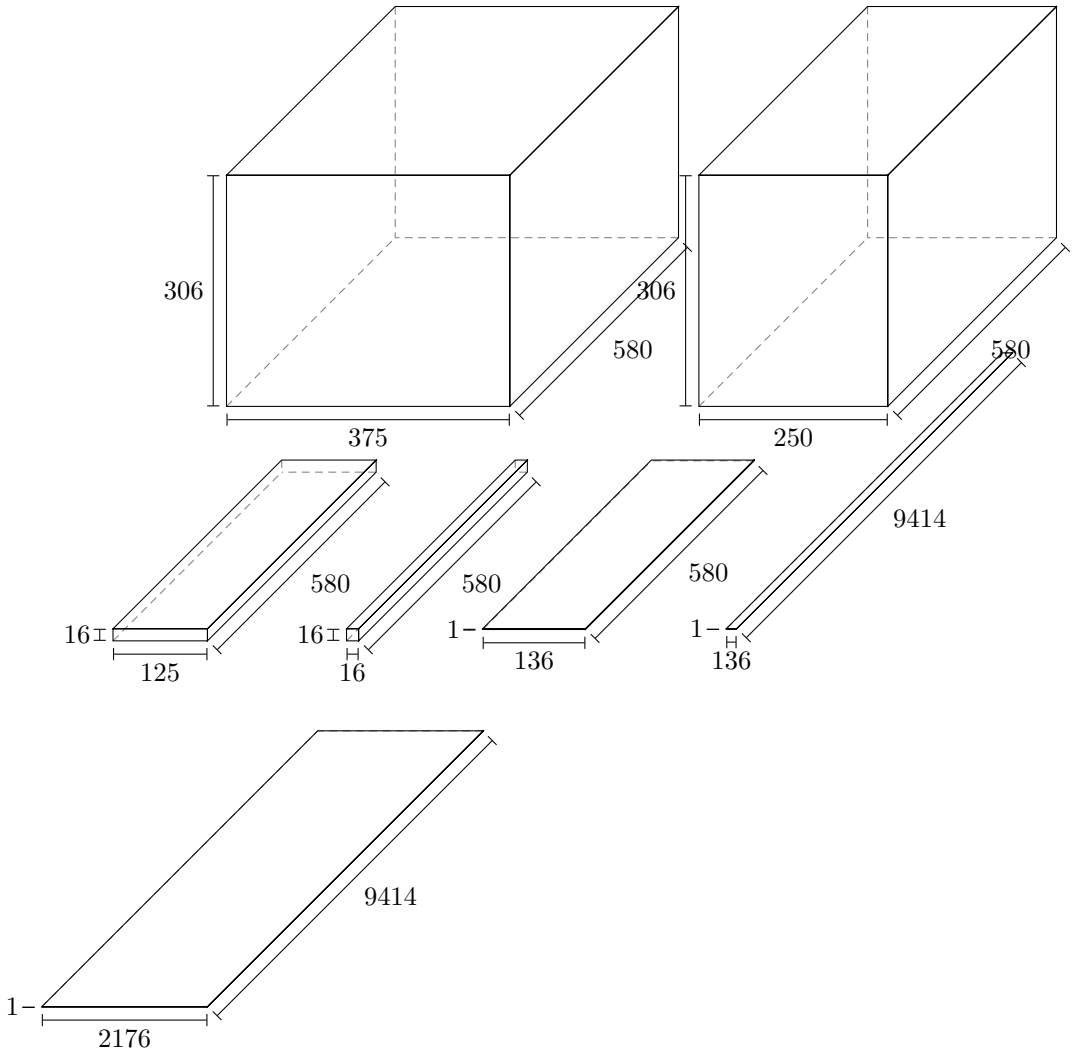

Part IV
Experimentations

1 Prise en main sur un dataset simple

1.1 Decription du dataset eye close/eye open

Ce dataset contient les données enregistré avec un casque EEG ou l'on a demandé au sujet d'ouvrir ou de fermer les yeux a certain moment. La tache a accomplir est de classifier a chaque enregistrement si la

personne a les yeux ouvert ou fermé.

Le signal est échantillonné à 512Hz. Il y a 7 femmes et 13 hommes pour un total de 20 participant pour ce dataset. L'age moyen est de 25.8 ans avec un écart type de 5.27 et une médiane a 25.5 ans. 18 sujets ont entre 19 et 28 ans et deux participants ont respectivement 33 ans et 44 ans.Le casque d'enregistrement est composé de 16 électrodes.

On commence par visualiser le signal des 16 électrodes ainsi que leurs labels associé au cours du temps.

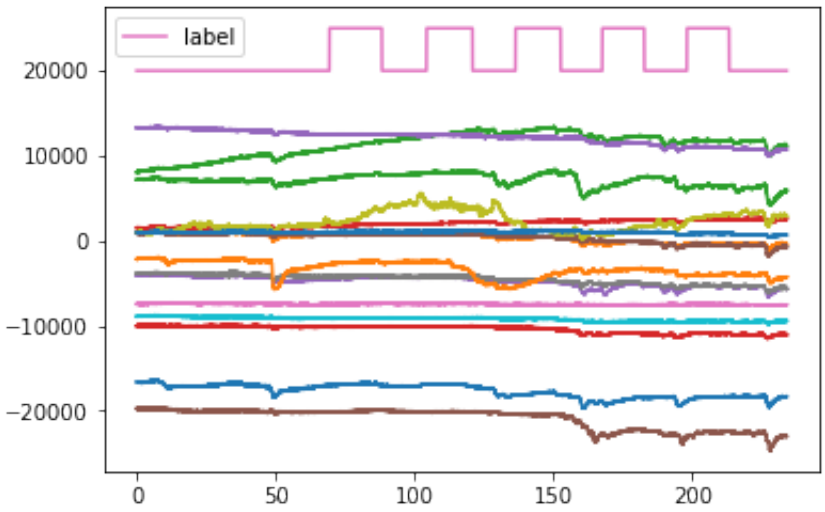

Figure 8: Affichage des données brut

1.2 Résultat des différents algorithmes

1.2.1 Valeurs de k pour les différents KNN

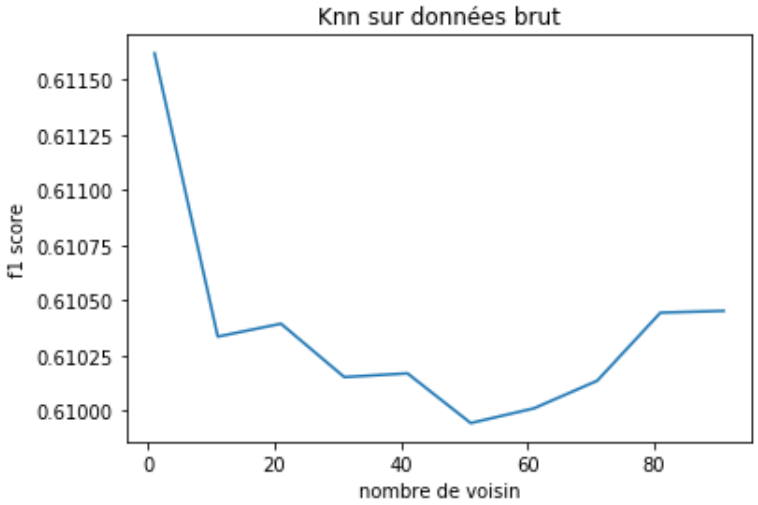

Figure 9: F1 Score(en cross validation) du knn en fonction du pourcentage des données utilisé pour le train

KNN sur les données brut $neigh = KNeighborsClassifier(n_neighbors = 10)$

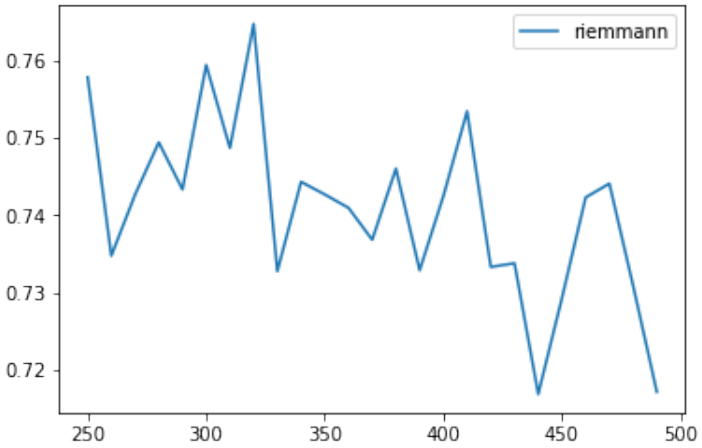

Figure 10: F1 Score(en cross validation) du Riemann knn en fonction du nombre de données par paquet

Riemann Cov KNN estimer la matrice de covariance
$cov = pyriemann.estimation.Covariances().fit_transform(X)$
validation croisée
$knn = pyriemann.classification.KNearestNeighbor(n_neighbors = 10)$

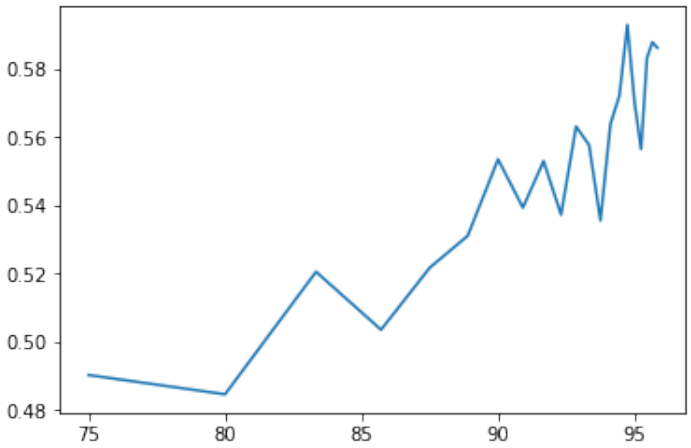

Figure 11: F1 Score(en cross validation) du knn en fonction du pourcentage des données utilisé pour le train

KNN filtre passe bas estimer la matrice de covariance
$neigh = KNeighborsClassifier(n_neighbors = 10) y_pred = cross_val_predict(neigh, donnees, labels, cv = k)$

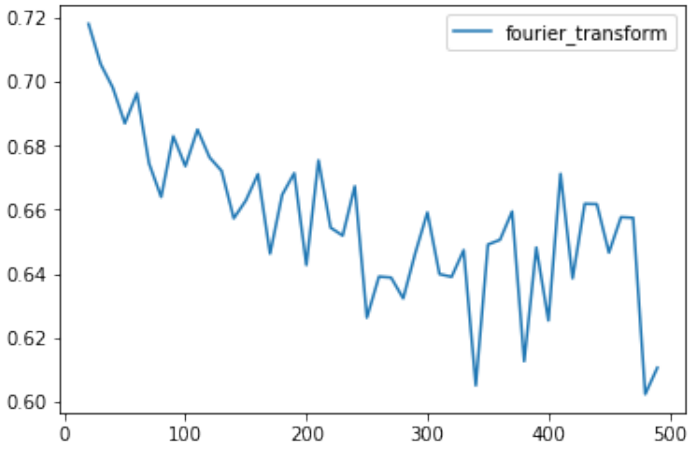

Figure 12: F1 Score(en cross validation) du knn en fonction

KNN transformée de fourier estimer la matrice de covariance
$cov = pyriemann.estimation.Covariances().fit_transform(X)$
validation croisée
$knn = pyriemann.classification.KNearestNeighbor(n_neighbors = 10)$

1.2.2 Etudes sur la longueur de la fennettre optimale

SVM sur les données brut $clf = SVM(max_iter = 10000, shuffle = True)$ Cross validation avec 5 parties :
F1 Score : 0.5390625

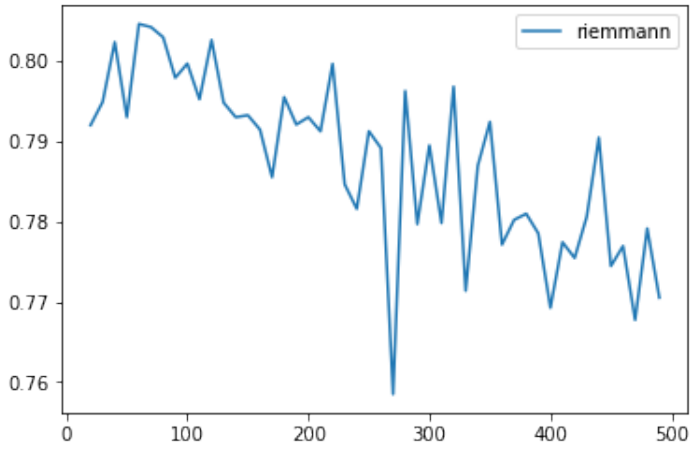

Figure 13: F1 Score(en cross validation) de riemann MDM en fonction du nombre de données par paquet

Riemann Cov MDM estimer la matrice de covariance
$cov = pyriemann.estimation.Covariances().fit_transform(X)$
validation croisée
$mdm = pyriemann.classification.MDM()$

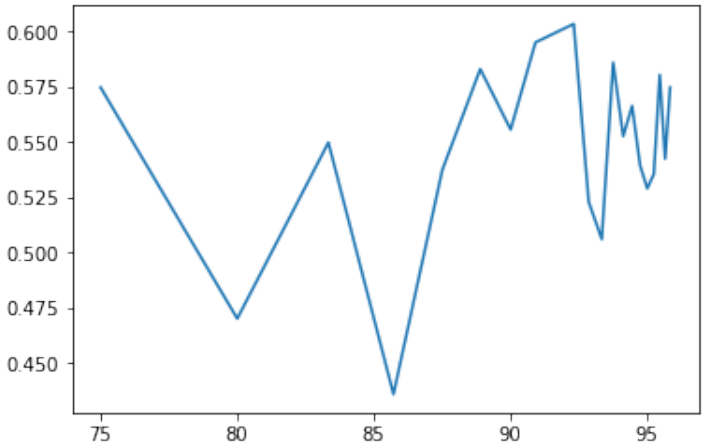

Figure 14: F1 Score(en cross validation) du SVM en fonction du pourcentage des données utilisé pour le train

SVM filtre passe bas modele :
$clf = SVM(max_iter = 10000, shuffle = True)$

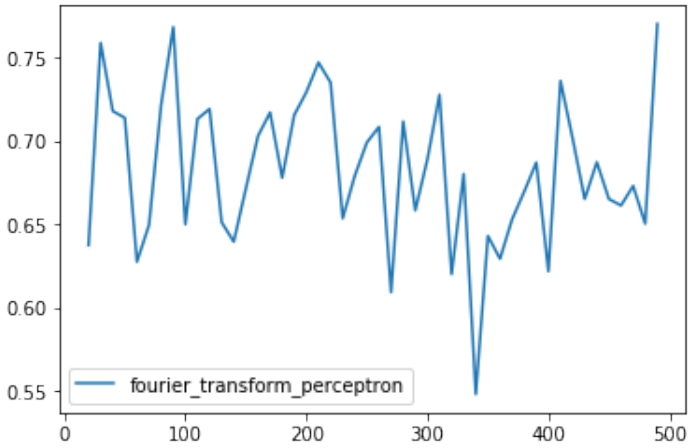

Figure 15: F1 Score(en cross validation) du SVM en fonction de la taille de la fenêtre

SVM transformée de fourier estimer la matrice de covariance
$cov = pyriemann.estimation.Covariances().fit_transform(X)$
validation croisée
$knn = pyriemann.classification.KNearestNeighbor(n_neighbors = 10)$

1.2.3 Tableau récapiltulatif

f1-score arrondie à deux chiffre apres la virgule.

Nom de l'algorithme	f1-score
les données brut	0.54
KNN sur les données brut	0.61
Riemann Cov MDM	0.84
Riemann Cov KNN	0.77
SVM filtre passe bas	0.60
KNN filtre passe bas	0.59
SVM transformée de fourier	0.77
KNN transformée de fourier	0.72

2 Brain Invader

2.1 Description de la tache de machine learning

Ce dataset à été enregistrer avec les sujets placer devant un pc ou une grille d'alien était représenté sur un écran.12 flashs dont 2 comprennent l'alien ciblé. Détecté les flash ou il y a l'alien en regardant l'activité cérébrale.Plusieurs tentative pour détruire l'alien.
Première tache : Classification binaire (le flash nous intéresse(il y a l'alien cible dedans) ou pas)
Deuxième tache : dans le groupe de 12 ou sont les deux flashs avec l'alien cible.

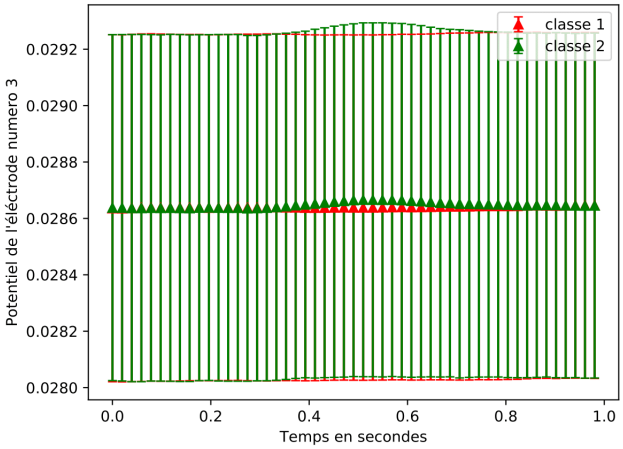

Figure 16: visuel classe mean std

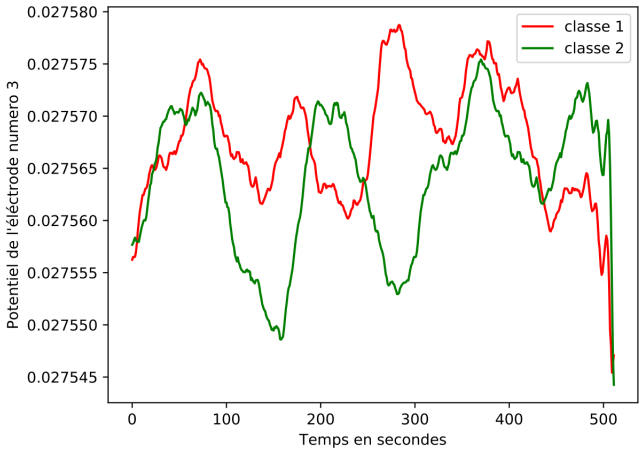

Figure 17: visuel data 0-1

F1-score des différents algorithme sur brain invader :

nom de l'algorithme	1 seconde	0.1 seconde	0.04 seconde
SVM brut	0.323051948051948	0.326461038961039	0.267532467532467
SVM tf	0.451136363636364	0.323051948051948	0.408313347178491
riemann MDM	0.441884775795033	0.450794330760887	0.441463342031226
knn brut	0.391033345601445	0.421304978708651	0.477791812169029
cov SVM	0.293170459768325	0.32987012987013	0.267283968878502
passe bas KNN	0.468170847379269	0.417829605960706	0.467431891494059
knn tf	0.399253802094698	0.470427433051929	0.453723364485908
passe bas SVM	0.267532467532467	0.326461038961039	0.451136363636364
conv1D	0.384761943288956	0.326461038961039	0.33686397710642

Il n'a pas été possible de comparer les résultats avec les résultats de l'auteur du dataset car il manquait la composition des groupe d'alien qui clignotait.

3 DecMeg2014

3.1 Description du dataset

La tache que l'on doit réaliser avec le dataset DecMeg2014 est une classification binaire. Le but est de déterminer si le stimulus visuel est un visage clair ou un brouiller qui est montré au participant.L'activité de leurs cerveaux est enregistrer grâce à un appareil de magnetoencéphalographie. Cet appareil dispose de 306 magnétomètres.
Ce dataset est extrait d'une compétition kaggle du même nom.
23 sujets on participé à ce test avec environ 580 trials par sujet. Nous disposons de 16 sujets avec leurs labels associé et 7 sujets ou nous avons uniquement les données.

3.2 Méthode d'évaluation

Sur le dernier dataset DecMeg2014 nous disposons des données pour 16 sujets, nous procéderons donc comme décris ci-dessous pour l'évaluation de nos différentes méthodes :
- entrainement sur une partie de 1 et eval sur 1 (validation croisée sur un seul)
- entrainement sur 1 et évaluation sur tous les autres (16 expériences a faire)
- entrainement sur 15 et évaluation sur 1 (16 expériences a faire)
- entrainement sur 16 et eval sur 16 tout mélanger avec validation croisée.

Ces façon d'évaluer nous permette de tester plusieurs caractéristique de nos modèles dont la capacité de transfert d'un sujet a l'autre.
Pour chaque test on sauvegardera le f1 score sur la classe minoritaire.

Part V
Conclusion

D'après nos résultat nous pouvons conclure que....
Il pourrais etre interessant de combiner des methodes de deep learning et de géometrie de riemann.

References

[1] M. Congedo, M. Goyat, N. Tarrin, G. Ionescu, L. Varnet, B. Rivet, R. Phlypo, N. Jrad, M. Acquadro, and C. Jutten, ""brain invaders": a prototype of an open-source p300- based video game working with the OpenViBE platform," p. 7.

[2] M. Congedo, A. Barachant, and R. Bhatia, "Riemannian geometry for EEG-based brain-computer interfaces; a primer and a review," vol. 4, no. 3, pp. 155–174.