

PLDAC - Etude de différentes techniques pour la classification de signaux d'EEG et MEG

Buton Nicolas

May 16, 2019



Table des matières

I	Introduction	1
II	La géométrie de riemann	1
1	Distance	2
2	Point moyen	2
3	Espace tangent	2
III	Les différentes méthodes	3
IV	Prise en main sur un dataset simple	3
1	Decription du dataset eye close/eye open	3
2	Résultat des différents algorithmes	4
2.1	les données brut	4
2.2	KNN sur les données brut	5
2.3	Riemann Cov MDM	5
2.4	Riemann Cov KNN	6
2.5	Perceptron filtre passe bas	7
2.6	KNN filtre passe bas	8
2.7	Perceptron transformée de fourier	9
2.8	KNN transformée de fourier	10
2.9	Tableau récapiltulatif	10
V	Brain Invader	10
1	Description de la tache de machine learning	11
VI	DecMeg2014	12
1	Description du dataset	12
2	Les différentes étapes	13
VII	Conclusion	15

Part I

Introduction

Les signaux étudiés seront des signaux d'Électroencéphalographie(EEG) et de Magnétoencéphalographie(MEG). Le premier consiste à enregistrer les signaux électriques à la surface du crâne grâce à des électrodes, le second enregistre l'activité magnétique induite par l'activité des neurones grâce à un ensemble de magnétomètres.

L'une des difficultés pour traiter ces signaux est le fait que les électrodes ne sont jamais situées exactement au même endroit sur le crâne entre chaque essai, et entre chaque personne. De plus il peut y avoir beaucoup de bruit généré par le matériel ou les mouvements de l'utilisateur par exemple.

Pour être résistant au bruit on a donc besoin de manipuler des matrices de covariance et pour cela un moyen est d'utiliser la géométrie de Riemann qui peut définir une distance entre matrices définies positives, les matrices de covariance font partie de ce groupe. La deuxième méthode consiste à aplatir la matrice.

C'est pour cela que dans les méthodes de l'état de l'art la géométrie riemannienne est utilisée. Ces méthodes permettent aussi un meilleur succès pour le transfert d'un sujet à un autre.

Par la suite nous allons comparer ces méthodes avec de la géométrie riemannienne avec d'autres méthodes plus classiques, ainsi qu'une méthode de deep learning.

Dans ce rapport nous étudierons nos méthodes sur 3 datasets différents : Eye close/eye open, brain invader et DecMeg2014.

Sur le dernier dataset DecMeg2014 nous disposons des données pour 16 sujets, nous procéderons donc comme décrit ci-dessous pour l'évaluation de nos différentes méthodes :

- entraînement sur une partie de 1 et eval sur 1 (validation croisée sur un seul)
- entraînement sur 1 et évaluation sur tous les autres (16 expériences à faire)
- entraînement sur 15 et évaluation sur 1 (16 expériences à faire)
- entraînement sur 16 et eval sur 16 tout mélanger avec validation croisée.

Ces façons d'évaluer nous permettent de tester plusieurs caractéristiques de nos modèles dont la capacité de transfert d'un sujet à l'autre.

Pour chaque test on sauvegardera le f1 score sur la classe minoritaire.

Part II

La géométrie de riemann

1 Distance

Pour deux matrice Σ_1 et Σ_2 leurs distances est d'après la géométrie de Riemann est la suivante :

$$\delta_R(\Sigma_1, \Sigma_2) = \|\log(\Sigma_1^{-1/2} \Sigma_2 \Sigma_1^{-1/2})\|_F = \left[\sum_{c=1}^C \log^2 \lambda_c \right]^{1/2}, \quad (1)$$

où $\lambda_c, c = 1 \dots C$ sont les valeurs propres réelles de $\Sigma_1^{-1/2} \Sigma_2 \Sigma_1^{-1/2}$ et C le nombre d'électrodes.
F :Norme de Frobenius

2 Point moyen

Pour définir la matrice moyenne nous ne possédons pas d'expression explicite.

$$\mathfrak{G}(\Sigma_1, \dots, \Sigma_I) = \arg \min_{\Sigma} \sum_{i=1}^I \delta_R^2(\Sigma, \Sigma_i). \quad (2)$$

Pour la calculer on peut utiliser une descente de gradient.

3 Espace tangent

On peut projeter un point de l'espace de Riemann défini par une matrice NxN sur un espace tangent avec $N(N+1)/2$ dimensions.





Figure 1: Affichage del'espace tangent

- Article sur la géométrie de Riemann :
- Brain invader [1]
 - Geometrie de riemann [2]

Part III

Les différentes méthodes

Nous allons représenter à l'aide d'un graphe les différentes méthodes que nous allons tester par la suite.



Légende :

Cov : Matrice de covariance

TF : Transformé de fourier

MDM : Minimum Distance to Mean

Prédiction théorique :

La méthode 6 et 7 ne devraient pas fonctionner car avec une seule donnée c'est difficile de faire quoi que ce soit.

La méthode 8 et 9 ne devraient pas fonctionner car il n'y aura pas d'invariance par translation.

De plus nous introduirons une nouvelle méthode plus complexe dans le dernier dataset DecMeg2014.

Part IV

Prise en main sur un dataset simple

1 Description du dataset eye close/eye open

Ce dataset contient les données enregistrées avec un casque EEG où l'on a demandé au sujet d'ouvrir ou de fermer les yeux à certain moment. La tâche à accomplir est de classer à chaque enregistrement si la personne a les yeux ouverts ou fermés.

Le signal est échantillonné à 512Hz. Il y a 7 femmes et 13 hommes pour un total de 20 participants pour ce dataset. L'âge moyen est de 25.8 ans avec un écart type de 5.27 et une médiane à 25.5 ans. 18 sujets ont entre 19 et 28 ans et deux participants ont respectivement 33 ans et 44 ans. Le casque d'enregistrement est composé de 16 électrodes.

On commence par visualiser le signal des 16 électrodes ainsi que leurs labels associé au cours du temps.




Figure 2: Affichage des données brut

2 Résultat des différents algorithmes

2.1 les données brut

$clf = \text{SGDClassifier}(loss = "perceptron", eta0 = 1e-4, learning_rate = "constant", penalty = None, tol = 1e-1, max_iter = 10000, shuffle = True)$ Cross validation avec 5 parties :
F1 Score : 0.5390625

2.2 KNN sur les données brut




Figure 3: F1 Score(en cross validation) du knn en fonction du pourcentage des données utilisé pour le train

$neigh = KNeighborsClassifier(n_neighbors = 10)$

2.3 Riemann Cov MDM




Figure 4: F1 Score(en cross validation) de riemann MDM en fonction du nombre de données par paquet

```

estimer la matrice de covariance
cov = pyriemann.estimation.Covariances().fit_transform(X)
validation croisée
mdm = pyriemann.classification.MDM()

```

2.4 Riemann Cov KNN




Figure 5: F1 Score(en cross validation) du Riemann knn en fonction du nombre de données par paquet

```

estimer la matrice de covariance
cov = pyriemann.estimation.Covariances().fit_transform(X)
validation croisée
knn = pyriemann.classification.KNearestNeighbor(n_neighbors = 10)

```


2.5 Perceptron filtre passe bas




Figure 6: F1 Score(en cross validation) du perceptron en fonction du pourcentage des données utilisé pour le train

modele :

```
clf = SGDClassifier(loss = "perceptron", eta0 = 1e-4, learning_rate = "constant", penalty = None, tol = 1e-1, max_iter = 10000, shuffle = True)
```

2.6 KNN filtre passe bas




Figure 7: F1 Score(en cross validation) du knn en fonction du pourcentage des données utilisé pour le train

estimer la matrice de covariance

$neigh = KNeighborsClassifier(n_neighbors = 10)$
 $y_{pred} = cross_val_predict(neigh, donnees, labels, cv = k)$

2.7 Perceptron transformée de fourier




Figure 8: F1 Score(en cross validation) du perceptron en fonction

estimer la matrice de covariance

```
cov = pyriemann.estimation.Covariances().fit_transform(X)
```

validation croisée

```
knn = pyriemann.classification.KNearestNeighbor(n_neighbors = 10)
```

2.8 KNN transformée de fourier




Figure 9: F1 Score(en cross validation) du knn en fonction

estimer la matrice de covariance

```
cov = pyriemann.estimation.Covariances().fit_transform(X)
```

validation croisée

```
knn = pyriemann.classification.KNearestNeighbor(n_neighbors = 10)
```

2.9 Tableau récapitulatif

f1-score arrondie à deux chiffre apres la virgule.

Nom de l'algorithme	f1-score
les données brut	0.54
KNN sur les données brut	0.61
Riemann Cov MDM	0.84
Riemann Cov KNN	0.77
Perceptron filtre passe bas	0.60
KNN filtre passe bas	0.59
Perceptron transformée de fourier	0.77
KNN transformée de fourier	0.72

Part V

Brain Invader

1 Description de la tache de machine learning

Ce dataset à été enregistré avec les sujets placer devant un pc ou une grille d'alien était représenté sur un écran. 12 flashs dont 2 comprennent l'alien ciblé. Détection des flashs où il y a l'alien en regardant l'activité cérébrale. Plusieurs tentatives pour détruire l'alien.

Première tâche : Classification binaire (le flash nous intéresse (il y a l'alien cible dedans) ou pas)

Deuxième tâche : dans le groupe de 12 où sont les deux flashs avec l'alien cible.




Figure 10: visuel classe mean std




Figure 11: visuel data 0-1

F1-score des différents algorithmes sur brain invader :

nom de l'algorithme	1 seconde	0.1 seconde	0.04 seconde
perceptron brut	0.323051948051948	0.326461038961039	0.267532467532467
perceptron tf	0.451136363636364	0.323051948051948	0.408313347178491
riemann MDM	0.441884775795033	0.450794330760887	0.441463342031226
knn brut	0.391033345601445	0.421304978708651	0.477791812169029
cov perceptron	0.293170459768325	0.32987012987013	0.267283968878502
passe bas KNN	0.468170847379269	0.417829605960706	0.467431891494059
knn tf	0.399253802094698	0.470427433051929	0.453723364485908
passe bas perceptron	0.267532467532467	0.326461038961039	0.451136363636364
conv1D	0.384761943288956	0.326461038961039	0.33686397710642

Il n'a pas été possible de comparer les résultats avec les résultats de l'auteur du dataset car il manquait la composition des groupes d'alien qui clignotait.

Part VI

DecMeg2014

1 Description du dataset

La tâche que l'on doit réaliser avec le dataset DecMeg2014 est une classification binaire. Le but est de déterminer si le stimulus visuel est un visage clair ou un brouiller qui est montré au participant. L'activité de leurs cerveaux est enregistrée grâce à un appareil de magnétoencéphalographie. Cet appareil dispose de 306 magnétomètres.

Ce dataset est extrait d'une compétition kaggle du même nom.

23 sujets ont participé à ce test avec environ 580 trials par sujet. Nous disposons de 16 sujets avec leurs labels associés et 7 sujets où nous avons uniquement les données.

2 Les différentes étapes

1 - On garde uniquement 1 seconde sur les 1.5 secondes de signal car le stimulus intervient qu'après 0.5 secondes.

2 - On filtre le signal avec un filtre passe bande de Butterworth d'ordre 5 entre 1Hz et 20Hz.




Figure 12: butterworth filter

3 - Par la suite on effectue un filtrage spatial, on extrait 4 channel virtuel par classe.

$$\mathbf{P}^{(k)} = \frac{1}{|\mathcal{I}^{(k)}|} \sum_{i \in \mathcal{I}^{(k)}} \mathbf{x}_i,$$

Figure 13: P moyen

$$\mathbf{w}^* = \arg \max_{\mathbf{w}} \frac{\mathbf{w}^T \mathbf{P}^{(k)} \mathbf{P}^{(k)T} \mathbf{w}}{\mathbf{w}^T \mathbf{X} \mathbf{X}^T \mathbf{w}}.$$

Figure 14: spatial filtering

$$\mathbf{Z}_i = \mathbf{W}^T \mathbf{X}_i$$

Figure 15: Zi

$$\tilde{\mathbf{Z}}_i = \begin{bmatrix} \mathbf{W}^{(0)T} \mathbf{P}^{(0)} \\ \mathbf{W}^{(1)T} \mathbf{P}^{(1)} \\ \mathbf{Z}_i \end{bmatrix}.$$

Figure 16: features space

$$\Sigma_i = \frac{1}{N} \tilde{\mathbf{Z}}_i \tilde{\mathbf{Z}}_i^T$$


Figure 17: covariance

- 4 - On définit une nouvelle entrée comme étant la concaténation :
 - du signal moyen de la classe 1 auquel on multiplie par \mathbf{W}_0 pour les projeter sur les channels virtuelles appris précédemment.
 - idem pour la classe 2
 - Et ensuite le signal \mathbf{X}_i projeter sur les 8 channels.
- 5 - On calcul la covariance de cette matrice.
- 6 - On projette cette matrice sur l'espace tangent.
- 7 - On estime pour les 15 autres sujets avec ce filtre spatial
- 8 - On fait la même chose pour les 15 autres sujet

et on concatène.

9 - Régression logistique avec une régularisation lasso.

Les figures suivantes représentent la forme des matrices au fur et à mesure du processus. Elles sont à lire de gauche à droite et de haut en bas.



Part VII

Conclusion

References

- [1] M. Congedo, M. Goyat, N. Tarrin, G. Ionescu, L. Varnet, B. Rivet, R. Phlypo, N. Jrad, M. Acquadro, and C. Jutten, “”brain invaders”: a prototype of an open-source p300- based video game working with the OpenViBE platform,” p. 7.
- [2] M. Congedo, A. Barachant, and R. Bhatia, “Riemannian geometry for EEG-based brain-computer interfaces; a primer and a review,” vol. 4, no. 3, pp. 155–174.